

Last Web Scraping Study

웹에서 정보를 자동으로 수집하기!

이번주 ...

1. **Selenium** 설치하고 알아보기
2. 포털에서 “**개설강좌조회**” 에 있는 과목 목록 가져오기



Selenium 설치해보기!

Selenium 이란?

Selenium은 웹 브라우저 **자동화**를 위한 강력한 도구 모음입니다. 주로 **웹 애플리케이션 테스트**에 사용되지만, **웹 스크래핑**이나 반복적인 웹 기반 작업을 자동화하는 데에도 널리 활용됩니다.

Pros

1. 실제 사용자 행동 모방
2. 광범위한 브라우저 및 플랫폼 지원
3. 다양한 프로그래밍 언어 지원

Cons

1. 상대적으로 느린 속도
2. 높은 시스템 자원 소모
3. 초기 설정의 번거로움

Selenium 설치 및 확인

bash

```
pip install selenium chromedriver_autoinstaller  
python w4/initialize.py
```

initialize.py

```
# chrome driver 테스트를 위한 코드  
import os  
import sys  
  
project_root = os.path.dirname(os.path.dirname(os.path.abspath(__file__)))  
sys.path.insert(0, project_root)  
  
from scraping.selenium_utils import initialize_driver  
  
# 테스트 드라이버 생성  
driver = initialize_driver()  
driver.quit()
```

Selenium 사용법

드라이버 초기화

```
driver = webdriver.Chrome()
```

요소 찾기

find_element(By 클래스, 조건) : By 클래스에 정의된 방법으로 조건을 만족하는 요소 하나만 찾습니다.

find_elements(find_element와 동일) : 조건을 만족하는 요소를 모두 찾습니다.

By Class

By.ID

By.NAME

By.CLASS_NAME

By.TAG_NAME

By.CSS_SELECTOR

By.XPATH

Selenium 사용법

XPATH

XPath는 HTML이나 XML 문서 내의 특정 요소(Element)나 속성(Attribute)을 찾아가는 경로

왜 사용할까요?

1. 복잡한 구조 탐색: ID나 Class가 없는 요소, 또는 여러 단계를 거쳐야 도달할 수 있는 깊은 곳의 요소도 찾아낼 수 있습니다.
2. 텍스트 내용 기반 검색: 특정 텍스트를 포함하는 요소를 찾을 때 유용합니다. (예: '로그인' 버튼 찾기)
3. 부모/조상 요소 탐색: 특정 요소를 기준으로 그 상위 요소를 찾아야 할 때 CSS 선택자보다 강력합니다.

기본적인 표현 방식:

- /: 루트(최상위) 요소부터 시작하거나, 바로 아래 자식 요소를 나타냅니다. (예: /html/body/div)
- //: 문서 내 어디서든 해당 요소를 찾습니다. (예: //button → 모든 버튼 요소) - 가장 많이 사용됩니다.
- tagname: HTML 태그 이름 (예: div, p, a)
- @attribute: 속성을 나타냅니다. (예: @id, @class, @href)
- []: 조건을 지정합니다.
- [@id='loginButton']: id 속성이 'loginButton'인 요소
- [text()='로그인']: 텍스트 내용이 정확히 '로그인'인 요소
- [contains(text(), '검색')]: 텍스트 내용에 '검색'이 포함된 요소
- [1], [2]: 여러 요소 중 특정 순서(1부터 시작)의 요소

Selenium 사용법

좀 더 똑똑하게 요소 찾기

```
WebDriverWait(driver, timeout).until(  
    EC.presence_of_element_located((By 클래스, 조건))  
)
```

→ find_element 와 동일하지만, 요소가 없으면 에러를 발생시키는 find_element 와 달리 이 방식은 정해진 timeout 까지는 요소를 찾는다. 이때 조건을 다양하게 지정할 수 있는데, 아래와 같다.

- presence_of_element_located(locator): 요소가 DOM에 존재할 때까지 기다림 (화면에 보이지 않아도 됨)
- visibility_of_element_located(locator): 요소가 DOM에 존재하고 화면에 보일 때까지 기다림.
- element_to_be_clickable(locator): 요소가 화면에 보이고 클릭 가능한 상태가 될 때까지 기다림.
- presence_of_all_elements_located(locator): 지정된 로케이터와 일치하는 모든 요소가 DOM에 존재할 때까지 기다림 (리스트 반환).
- visibility_of_all_elements_located(locator): 지정된 로케이터와 일치하는 모든 요소가 화면에 보일 때까지 기다림 (리스트 반환).
- invisibility_of_element_located(locator): 요소가 화면에서 사라질 때까지 기다림.
- text_to_be_present_in_element(locator, text): 특정 요소 안에 특정 텍스트가 포함될 때까지 기다림.
- alert_is_present(): 경고창(Alert)이 나타날 때까지 기다림.

Selenium 사용법

Selenium driver에 취할 수 있는 액션

- `driver.get("URL")`: 지정된 URL로 이동합니다.
- `quit()`: 모든 브라우저 창을 닫고 웹 드라이버 세션을 종료합니다. (스크립트 마지막에 필수)
- `close()`: 현재 활성화된 브라우저 창 또는 탭 하나만 닫습니다.
- `refresh()`: 현재 페이지를 새로고침합니다.
- `back()`: 브라우저의 '뒤로 가기' 기능을 실행합니다.
- `forward()`: 브라우저의 '앞으로 가기' 기능을 실행합니다.
- `current_url`: 현재 페이지의 URL 주소를 문자열로 반환합니다. (속성)
- `title`: 현재 페이지의 `<title>` 태그 내용을 문자열로 반환합니다. (속성)
- `page_source`: 현재 페이지의 전체 HTML 소스 코드를 문자열로 반환합니다. (속성)
- `switch_to.frame("frame_name_or_id_or_index")`: 지정된 프레임(iframe)으로 제어 컨텍스트를 전환합니다.
- `switch_to.default_content()`: 프레임에서 원래의 기본 페이지 컨텍스트로 돌아옵니다.
- `switch_to.window("window_handle")`: 다른 브라우저 창이나 탭으로 제어 컨텍스트를 전환합니다.
- `window_handles` : 핸들 목록 확인
- `switch_to.alert`: 자바스크립트 경고(alert), 확인(confirm), 프롬프트(prompt) 창으로 제어 컨텍스트를 전환
- `execute_script("javascript_code")`: 브라우저에서 직접 자바스크립트 코드를 실행합니다. (예: 스크롤, 요소 강제 클릭 등)
- `get_cookies()`: 현재 페이지의 모든 쿠키 정보를 리스트 형태로 가져옵니다.
- `add_cookie({"name": "key", "value": "val"})`: 쿠키를 추가합니다.
- `delete_cookie("cookie_name")`: 특정 이름의 쿠키를 삭제합니다.
- `delete_all_cookies()`: 모든 쿠키를 삭제합니다.
- `save_screenshot("filename.png")`: 현재 보이는 화면을 스크린샷으로 저장합니다.

Selenium 사용법

Selenium element에 취할 수 있는 액션

- `element.click()`: 요소를 클릭합니다. (버튼, 링크, 라디오 버튼, 체크박스 등)
- `send_keys("text")`: 요소에 텍스트를 입력합니다. (주로 `<input>`, `<textarea>`) 특수 키(Enter, Tab 등)도 보낼 수 있습니다
 - `from selenium.webdriver.common.keys import Keys`: 각종 키에 대해 정의된 클래스
- `clear()`: 요소에 입력된 텍스트를 지웁니다. (`<input>`, `<textarea>`)
- `submit()`: 해당 요소가 포함된 폼(form)을 제출합니다. 종종 엔터키를 누르는 것과 동일하게 동작합니다.
- `text`: 요소 내부에 보이는 텍스트(content)를 문자열로 반환합니다. (속성)
- `get_attribute("attribute_name")`: 요소의 특정 속성(attribute) 값을 문자열로 반환합니다. (예: href, src, class, id, value 등)
- `is_displayed()`: 요소가 현재 화면에 보이는 상태인지 여부를 `boolean(True/False)`으로 반환합니다.
- `is_enabled()`: 요소가 활성화되어 상호작용 가능한 상태인지 여부를 `boolean`으로 반환합니다. (예: 클릭 가능한 버튼)
- `is_selected()`: 요소가 선택된 상태인지 여부를 `boolean`으로 반환합니다. (주로 체크박스, 라디오 버튼, 옵션 태그)
- `tag_name`: 요소의 HTML 태그 이름을 문자열로 반환합니다. (예: 'div', 'a', 'input') (속성)
- `location`: 요소의 페이지 내 위치 좌표({'x': int, 'y': int})를 딕셔너리로 반환합니다. (속성)
- `size`: 요소의 크기({'height': int, 'width': int})를 딕셔너리로 반환합니다. (속성)
- `find_element(By, "value")`: 해당 요소의 하위에서 조건에 맞는 첫 번째 요소를 찾습니다.
- `find_elements(By, "value")`: 해당 요소의 하위에서 조건에 맞는 모든 요소를 리스트로 반환합니다.

포털에서 개설강좌조회 하기

앞에서 배운 것들을 활용해 실제 스크래핑에 활용해 봅시다!

How...?

시나리오

1. 포털에 로그인한다.
2. 로그인된 페이지에서 종합정보시스템에 들어간다.
3. 새로운 탭에서 종합정보시스템이 열리는데 해당 페이지에서 학부 > 개설강좌조회 를 클릭한다.
4. 조회를 눌러 모든 과목 정보를 가져온다.
5. 이 정보를 파일로 저장한다.

대략 이런 식으로 시나리오를 구성하고 코드를 짜면 좀 더 수월합니다!

How...?

포털에 로그인한다.

- 1. 학번/사번 입력 칸을 찾는다.
- 2. 학번/사번을 입력하는 곳을 클릭한다.
- 3. 그 곳에 알맞은 정보를 입력한다.
- 4. 비밀번호에 대해서도 마찬가지로 수행한다.
- 5. LOGIN 버튼을 찾는다.
- 6. 버튼을 클릭한다.

수원대학교 포털시스템

UNIVERSITY OF SUWON PORTAL SYSTEM

English

THE UNIVERSITY OF SUWON

USW

수원대학교

종합정보시스템

도서관

취업지원처

연구산학

웹메일

평생교육원

일반로그인

공인인증서로그인

학번/사번

비밀번호

☐ 학번/사번 저장

LOGIN

학번/사번 찾기 및 비밀번호 재발급

수강신청 바로가기

통합공지

학과공지

취업

창업

대학원공지

국제협력공지

MORE

어학원공지

포털공지

장학공지

• 2025년 1학기 [융합수업 설계지원] 프로그램 선정 결과 안...

25.04.11

• 2025년 1학기 [혁신 교수법 지원] 프로그램 선정 결과 안내

25.04.11

• 2025 IT부트캠프&인턴십 통합과정 참여자 모집 안내

25.04.11

• 2025년 재학생(외국인유학생, 대학원생) 대상 통합폭력예방...

25.04.10

• 2025-1학기 등록금 분할납부 4차 등록기간 안내

25.04.10

• 2025년도 전반기 예비군훈련 수정 공고

25.04.09

• 음악대학 외 6개소 수변전실 노후변압기 및 부대설비 교체 ...

25.04.09

• [외부프로그램] 면접왕 이형과 함께하는 체인지업 프로젝트

25.04.09

• 2025학년도 제1회 성공창업멘토특강 안내

25.04.09

• 김건희 작가 특강 안내

25.04.09

바로가기

Heyoung Campus

포털시스템 도움말
이용안내

031) 229-8400(포털)
220-2278(포털)
220-2114(대표)

원격지원시스템

수원대학교 홈페이지

개인정보처리방침

개인정보제공 공시

이메일무단수집거부

정보보호

18323 경기도 화성시 봉담읍 와우안길 17 | 대표전화 : 031-220-2114

copyrights(c) 2012 The university of suwon. all rights reserved.

How...?

포털에 로그인한다 - .env 파일 알아보기

학번, 비밀번호 같은 **개인정보**는 코드에 넣으면 위험하다. ex) API KEY, 아이디 등 ...
이런 하드코딩으로 인한 위험을 막기 위해서 존재하는 것이 **.env** 파일이다.

```
bash
```

```
pip install dotenv
```

```
.env
```

```
PORTAL_ID={학번}  
PORTAL_PASSWORD={비밀번호}
```

```
env.py
```

```
# dotenv 테스트를 위한 코드  
import os  
from dotenv import load_dotenv  
  
load_dotenv()  
  
print(os.getenv('PORTAL_ID'))  
print(os.getenv('PORTAL_PASSWORD'))
```

How...?

포털에 로그인한다

selenium_login.py

```
# 로그인 페이지로 이동
driver.get("http://portal.suwon.ac.kr/enview/index.html")
print(f"로그인 페이지 로딩: {driver.title}")

# mainFrame이 나타날 때까지 명시적으로 대기 후 해당 프레임으로 전환
WebDriverWait(driver, 10).until(
    EC.presence_of_element_located((By.NAME, "mainFrame"))
)
driver.switch_to.frame("mainFrame")
print("로그인 프레임으로 전환 완료.")

# 아이디, 비밀번호 필드를 찾아 값 입력
username_field = driver.find_element(By.NAME, "userId")
password_field = driver.find_element(By.NAME, "pwd")
# 자동 완성 문제 방지를 위해 필드 내용 먼저 클리어
username_field.clear()
password_field.clear()
username_field.send_keys(user_id)
password_field.send_keys(password)
print("아이디 및 비밀번호 입력 완료.")

# 로그인 버튼을 찾아 클릭
login_button = driver.find_element(By.CLASS_NAME, "mainbtn_login")
login_button.click()
print("로그인 버튼 클릭 완료.")

# 로그인 성공 후 나타나는 요소 대기 (로그인 및 페이지 로딩 확인용)
WebDriverWait(driver, 20).until(
    EC.visibility_of_element_located((By.XPATH, "//body"))
)
print("로그인 후 메인 페이지 로딩 확인됨.")
```

login.py

```
# selenium_login.py 테스트를 위한 코드
import os
import sys

project_root = os.path.dirname(os.path.dirname(os.path.abspath(__file__)))
sys.path.insert(0, project_root)

from scraping.selenium_utils import initialize_driver
from scraping.selenium_login import login_with_selenium

import dotenv

dotenv.load_dotenv()

# 테스트 드라이버 생성
driver = initialize_driver()
try:
    login_with_selenium(driver, os.getenv('PORTAL_ID'), os.getenv('PORTAL_PASSWORD'))
finally:
    driver.quit()
```


How...?

시나리오

1. 포털에 로그인한다.
2. **로그인된 페이지에서 종합정보시스템에 들어간다.**
3. 새로운 탭에서 종합정보시스템이 열리는데 해당 페이지에서 학부 > 개설강좌조회 를 클릭한다.
4. 조회를 눌러 모든 과목 정보를 가져온다.
5. 이 정보를 파일로 저장한다.

대략 이런 식으로 시나리오를 구성하고 코드를 짜면 좀 더 수월합니다!

How...?

로그인된 페이지에서 종합정보시스템에 들어간다.

1. 종합정보시스템을 찾는다.
2. 클릭한다.

main.py

```
def go_to_info_page(driver):
    """로그인 후 정보 페이지로 이동합니다."""
    try:
        # 헤더의 정보 버튼이 클릭 가능할 때까지 대기
        info_button = WebDriverWait(driver, 10).until(
            EC.element_to_be_clickable((By.XPATH, "//div[@class='header']/div/div/ul/li[1]"))
        )
        # 정보 버튼 클릭
        info_button.click()
        print("정보 버튼 클릭 성공.")
    except TimeoutException:
        # 지정된 시간 내에 버튼을 찾거나 클릭할 수 없는 경우
        print("정보 버튼을 찾거나 클릭하는 데 실패했습니다.")
        raise Exception("정보 버튼 클릭 실패") # 오류 발생시키고 종료
```



수원대학교 포털시스템

UNIVERSITY OF SUWON PORTAL SYSTEM

학생포탈

정우창
데이터과학부
세션종료 20분 남음
현재 접속 IP
221.149.245.105
최종 로그인 시간
2025-04-11 18:26

로그아웃 정보설정

웹메일 바로가기

읽지않은 메일 건수 **59 건**

도서관 바로가기

도서대출건수 **0 건**
도서연체건수 **0 건**

수원대학교 canvas
서비스 바로가기

교수님 찾기

전화번호 검색

실문조사

백신보안

선택 문 상단장구

개인정보 보호포록

공공소프트웨어

종합정보시스템
도서관
평생교육원
연구산학
수원광장
수원대학교 | Q&A | FAQ | 교내외사이트모음 | 도움말

통합공지

• 2025년 1학기 [융합수업 설계지원] 프로그램 선정 결...	25.04.11
• 2025년 1학기 [혁신 교수법 지원] 프로그램 선정 결과...	25.04.11
• 2025 1부트캠프&인턴십 통합과정 참여자 모집 안내	25.04.11
• 2025년 재학생(외국인유학생, 대학원생) 대상 통합폭...	25.04.10
• 2025-1학기 등록금 분할납부 4차 등록기간 안내	25.04.10

MORE >

학과공지

• 커뮤니티에센디자인학과 시각전선실 교육조교 모집 ...	25.04.01
• [회계학과] 공인회계사반 입실 희망자 모집 안내	25.03.17
• 정보통신학부 사물함 내용물 보관 및 2025년 사물함 ...	25.03.11
• 전자물리학과 교육조교 모집 안내	25.02.25
• 창업팀 융복합전공 - KDB STARTUP 한국산업은행 화...	25.02.21

MORE >

일	화	수	목	금	2025-04-12(토)	MORE
1						
2						
3						
4						
5						

장학/대출

• 국회기술평화도림 2025 기후변화 정책상 선발공고	25.04.08
• (장학) 2025-1 추가간정장학 최종승인자 서류 제출 안내	25.04.08
• (장학) 2025년 푸른세대 양성기부장학금 신규장학생 ...	25.04.08
• (대출) 2025년 경기도 학자금 대출 지원연제자 인용...	25.04.03
• (장학) 중소기업창업연계(희망사다리1)장학금 신...	25.04.03

학사 일정

증명서 인터넷발급

증명서 우편신청

취업 지원처

오늘의 식단표

서울버스 시간표

전산 서비스

Office 365

[EN] [포탈공지] [개인정보 공지] **[원격지원]** [보안뉴스] [개인정보처리방침] [교육부 전자서명인증센터]

(18323) 경기도 학생시 봉담읍 와우만길 17

전화번호 : 031-220-2114

copyrights(c) 2012 The university of suwon, all rights reserved.

패밀리아이티 <v>

회원정보 **모델시스템** **종합정보시스템**

How...?

시나리오

1. 포털에 로그인한다.
2. 로그인된 페이지에서 종합정보시스템에 들어간다.
3. **새로운 탭에서 종합정보시스템이 열리는데 해당 페이지에서 학부 > 개설강좌조회 를 클릭한다.**
4. 조회를 눌러 모든 과목 정보를 가져온다.
5. 이 정보를 파일로 저장한다.

대략 이런 식으로 시나리오를 구성하고 코드를 짜면 좀 더 수월합니다!

How...?

새로운 탭에서 종합정보시스템이 열리는데 ...

이런식으로 새 탭이나 팝업으로 열리면 driver 가 더 이상 접근하지 못하기 때문에 driver.switch_to.window 을 사용해 창을 전환해야 한다.

main.py

```
# --- 3단계: 새 창/탭으로 전환 ---
print("새 창/탭으로 전환 시도 중...")
# 새 창이 완전히 열릴 시간을 확보하기 위해 잠시 대기 (필요에 따라 조절)
time.sleep(3)
switch_to_new_window(driver)
print(f"새 창으로 전환 완료. 현재 URL: {driver.current_url}")
```

USW

수원대학교

체의 장 아름다운 공동체의 장 아

정보광장

정보광장

업무메뉴

즐거찾기

장의자료게시판

학부

신상정보수정(학생)

종합정보조회(학생)

개설강좌조회(학생)

수업계획서 조회

교과과정조회

등록금고지서출력

등록금납입확인서

분할등록신청(학부)

교육비납입증명서(연말정산)

성적표출력

증명서 우편신청

증명서 인터넷 발급

시간표조회(학생용)

수강신청확인원출력(학생)

동일/대체과목조회

동일/대체과목출력

폐설과목알람표

유사교과목 목록

등록금환불신청

해당학기성적조회

강의평가등록(학생)

중간강의평가(학생)

계절학기 고지서 출력(학생)

휴학 신청(학생)

군휴학신청(학생)

자퇴신청(학생)

교양 프로그램 신청

전공배정신청(학생용)

전공변경신청(학생)

예비군

학생상담/설문

국제협력

기숙사

풋살/테니스장대관

개인정보 수집 · 이용 제공 동의서

개설강좌조회(학생)

개설강좌조회(학생) (SA_SU_4017.xml)

개설년도 2025

개설학기 1학기

요일/시간 -전체-

대학 -전체-

학과 -전체-

전공 -전체-

교과목명

이수구분 -전체-

교양영역 -전체-

개설학년 -전체-

책임교수

개설강좌

총건수 : 2457

순번	번호	교과목명	분반	추가정보	이수구분	학점	이론	실습	개설학과	대상학년	시간표	합반번호	동영상강좌	독서인증	성적처리	대표교수	교양영역
1	10853	도전과창조-기입가정신	001		중핵	2	2	0	인성교양대학>>교양	1	미레521(화7.8)		☐	☐	ABCDF	강성민	
2	10853	도전과창조-기입가정신	002		중핵	2	2	0	인성교양대학>>교양	1	글경503(금9.10)		☐	☐	ABCDF	김동주	
3	10853	도전과창조-기입가정신	003		중핵	2	2	0	인성교양대학>>교양	1	미레520(수1.2)		☐	☐	ABCDF	김상준	
4	10853	도전과창조-기입가정신	004		중핵	2	2	0	인성교양대학>>교양	1	미레105(목1.2)		☐	☐	ABCDF	김상준	
5	10853	도전과창조-기입가정신	005		중핵	2	2	0	인성교양대학>>교양	1	미레105(수3.4)		☐	☐	ABCDF	김성민	
6	10853	도전과창조-기입가정신	006		중핵	2	2	0	인성교양대학>>교양	1	미레105(수3.4)		☐	☐	ABCDF	김성민	
7	10853	도전과창조-기입가정신	007		중핵	2	2	0	인성교양대학>>교양	1	미레520(월5.6)		☐	☐	ABCDF	김영출	
8	10853	도전과창조-기입가정신	008		중핵	2	2	0	인성교양대학>>교양	1	미레104(화5.6)		☐	☐	ABCDF	김준태	
9	10853	도전과창조-기입가정신	009		중핵	2	2	0	인성교양대학>>교양	1	미레104(화7.8)	10853-009	☐	☐	ABCDF	김준태	
10	10853	도전과창조-기입가정신	010		중핵	2	2	0	인성교양대학>>교양	1	미레104(화1.2)		☐	☐	ABCDF	김진형	
11	10853	도전과창조-기입가정신	011		중핵	2	2	0	인성교양대학>>교양	1	미레104(화3.4)		☐	☐	ABCDF	김진형	
12	10853	도전과창조-기입가정신	012		중핵	2	2	0	인성교양대학>>교양	1	미레B106(화1.2)		☐	☐	ABCDF	김창희	
13	10853	도전과창조-기입가정신	013		중핵	2	2	0	인성교양대학>>교양	1	미레105(월5.6)		☐	☐	ABCDF	김현철	
14	10853	도전과창조-기입가정신	014		중핵	2	2	0	인성교양대학>>교양	1	미레105(월7.8)		☐	☐	ABCDF	김현철	
15	10853	도전과창조-기입가정신	015		중핵	2	2	0	인성교양대학>>교양	1	미레103(화3.4)		☐	☐	ABCDF	박두식	
16	10853	도전과창조-기입가정신	016		중핵	2	2	0	인성교양대학>>교양	1	미레521(화5.6)		☐	☐	ABCDF	박두식	
17	10853	도전과창조-기입가정신	017		중핵	2	2	0	인성교양대학>>교양	1	미레520(화1.2)		☐	☐	ABCDF	박현아	
18	10853	도전과창조-기입가정신	018		중핵	2	2	0	인성교양대학>>교양	1	미레520(화5.6)		☐	☐	ABCDF	박현아	
19	10853	도전과창조-기입가정신	019		중핵	2	2	0	인성교양대학>>교양	1	미레104(수1.2)		☐	☐	ABCDF	박효남	
20	10853	도전과창조-기입가정신	020		중핵	2	2	0	인성교양대학>>교양	1	미레104(수3.4)	10853-020	☐	☐	ABCDF	박효남	
21	10853	도전과창조-기입가정신	022		중핵	2	2	0	인성교양대학>>교양	1	미레520(목3.4)		☐	☐	ABCDF	박홍수	
22	10853	도전과창조-기입가정신	023		중핵	2	2	0	인성교양대학>>교양	1	미레520(목5.6)		☐	☐	ABCDF	박홍수	
23	10853	도전과창조-기입가정신	024		중핵	2	2	0	인성교양대학>>교양	1	미레520(목1.2)		☐	☐	ABCDF	서정석	
24	10853	도전과창조-기입가정신	025		중핵	2	2	0	인성교양대학>>교양	1	미레520(금3.4)		☐	☐	ABCDF	신동수	
25	10853	도전과창조-기입가정신	026		중핵	2	2	0	인성교양대학>>교양	1	미레520(금5.6)		☐	☐	ABCDF	신동수	

How...?

해당 페이지에서 학부 > 개설강좌조회 를 클릭

이제 창을 전환했으니 값을 가져오면 된다. 여기서 두가지 방식을 고려할 수 있다.

1. 요소 접근을 통해 값을 가져온다.
2. 데이터 fetch url 을 알아낸다.

1 번은 직관적이고 쉽지만, 변수가 많아 안정성이 떨어진다. 반면 2번은 알아내는 것이 어렵고 인증 등 신경 쓸 문제가 많지만, 알아낸다면 빠르고 안정적으로 값을 가져올 수 있다.

	element access	fetch
구현	쉬움	어려움
안정성	X	O
속도	느림	빠름

How...?


네이버 웹툰 스크래핑에서 배운 것을 활용해서 fetch 데이터 찾아보기

이런 식으로 어렵지 않게 알아낼 수 있음.

그러나 이 데이터는 인증이 필요한 데이터이므로 “로그인이 필요한 사이트 스크래핑”에서 배운 쿠키 관리가 필요합니다.

헤더에 있는 정보를 잘 분석해서 필요한 정보를 추출해 그대로 넘겨주어야 한다.

네이버 웹툰 : fetch url 알아내기, json 데이터 다루기
로그인이 필요한 사이트 : 헤더와 세션(쿠키)



How...?

쿠키 정보 가져오기

selenium_utils.py

```
def get_requests_session_with_cookies(driver):
    selenium_cookies = driver.get_cookies() # 드라이버에서 쿠키 가져오기
    requests_session = requests.Session() # requests 세션 생성

    print(f"Selenium에서 {len(selenium_cookies)}개의 쿠키 추출됨. requests 세션으로 변환 중...")
    # Selenium 쿠키를 requests 세션에 추가
    for cookie in selenium_cookies:
        # 'expiry' 키 처리 (requests는 'expires' 사용)
        if 'expiry' in cookie:
            # 값이 None이 아닐 경우 정수로 변환
            expiry_val = cookie.get('expiry')
            cookie['expires'] = int(expiry_val) if expiry_val is not None else None
            del cookie['expiry']

    # requests가 인식하는 키만 필터링 (cookie.get 사용으로 안전하게 접근)
    cookie_args = {
        'name': cookie.get('name'),
        'value': cookie.get('value'),
        'domain': cookie.get('domain'),
        'path': cookie.get('path'),
        'expires': cookie.get('expires'),
        'secure': cookie.get('secure', False), # 없으면 False로 기본값 설정
    }

    cookie_args = {k: v for k, v in cookie_args.items() if v is not None}

    # name과 value가 모두 존재할 경우에만 쿠키 추가
    if cookie_args.get('name') is not None and cookie_args.get('value') is not None:
        try:
            requests_session.cookies.set(**cookie_args)
        except Exception as e:
            print(f"쿠키 설정 중 오류 발생 ({cookie.get('name')}): {e}")
            print(f"오류 발생 쿠키 정보: {cookie_args}")
    else:
        print(f"이름 또는 값이 없어 쿠키를 건너뛴: {cookie}")

    print(f"requests 세션에 {len(requests_session.cookies)}개의 쿠키 설정 완료.")
    return requests_session
```

헤더 구성해서 request 보내기

api_interaction.py

```
def fetch_subjects_api(session, url, data, custom_headers=None):
    headers = DEFAULT_HEADERS.copy() # 기본 헤더 복사
    if custom_headers:
        headers.update(custom_headers) # 사용자 정의 헤더 병합/덮어쓰기

    response = None # 응답 변수 초기화
    try:
        print(f"API 요청 시작: {url}")
        response = session.post(url, headers=headers, json=data)
        response.raise_for_status() # 오류 상태 코드(4xx 또는 5xx) 시 예외 발생
        subjects_data = response.json() # text, content 는 plain text
        print("API 요청 성공")
        return subjects_data
    except requests.exceptions.RequestException as e:
        print(f"API 요청 실패 (RequestException): {e}")
        if response is not None:
            print(f"응답 상태 코드: {response.status_code}")
            return None
    except json.JSONDecodeError:
        print("JSON 파싱 실패")
        if response is not None:
            print(f"응답 상태 코드: {response.status_code}")
            print(f"응답 내용: {response.text[:500]}...") # 디버깅 위해 처음 500자 출력
            return None
    except Exception as e:
        print(f"API 호출 중 예상치 못한 오류 발생: {e}")
        return None
```

How...?

시나리오

1. 포털에 로그인한다.
2. 로그인된 페이지에서 종합정보시스템에 들어간다.
3. ~~새로운 탭에서 종합정보시스템이 열리는데 해당 페이지에서 학부 > 개설강좌조회~~를 클릭한다.
4. ~~조회를 눌러 모든 과목 정보를 가져온다.~~
5. **이 정보를 파일로 저장한다.**

대략 이런 식으로 시나리오를 구성하고 코드를 짜면 좀 더 수월합니다!

How...?

“파일 저장하기”에서 배운 JSON 을 로컬 저장소에 저장하기

file_utils.py

```
def save_json(json_data, output_dir='output', filename='output.json'):
    if json_data:
        try:
            os.makedirs(output_dir, exist_ok=True) # 출력 디렉토리가 없으면 생성
            output_file = os.path.join(output_dir, filename)
            with open(output_file, 'w', encoding='utf-8') as f:
                json.dump(json_data, f, ensure_ascii=False, indent=4)
            print(f"데이터를 {output_file} 에 저장했습니다.")
        except Exception as e:
            print(f"JSON 파일 저장 중 오류 발생: {e}")
    else:
        print("저장할 데이터가 없습니다.")
```

main.py

```
# --- 8단계: 결과 저장 ---
if subjects_data:
    # 가져온 데이터를 JSON 파일로 저장 (최상위 'output' 디렉토리에)
    output_path = os.path.join(project_root, 'output')
    save_json(subjects_data, filename='subjects_list.json', output_dir=output_path)
else:
    print("API로부터 데이터를 받지 못해 파일을 저장하지 않습니다.")
```


데이터 다루기

저장된 subject_list.json 을 Pandas 로 불러와 DataFrame 으로 만들기

```
w4 > data_info.ipynb > ...
+ Code + Markdown | ▶ Run All ↺ Restart ≡ Clear All Outputs | [X] Jupyter Variables ≡ Outline ...

▶ ▼
• import pandas as pd
  import json

  pd.set_option('display.max_columns', None)

  with open('../output/subjects_list.json') as f:
      data = json.loads(f.read())

  df = pd.DataFrame(data['estbLectDtaiList'])

  print(df.info())

  df_simple = df[["diclNo", "subjtNm", "ltrPrfsNm", "timtSmryCn", "estbDpmjNm", "trgtGrdeCd"]]
  df[(df_simple["estbDpmjNm"] == "데이터과학부") & (df_simple["trgtGrdeCd"] == 4)]

[1]
...
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2968 entries, 0 to 2967
Data columns (total 65 columns):
#   Column      Non-Null Count  Dtype
---  -
0   subjtEstbYear  2968 non-null    object
1   cretPblntfYn  2968 non-null    object
2   lssnLangCd    2898 non-null    object
3   timtSmryCn    2388 non-null    object
4   reprPrfsEnoNm  2926 non-null    object
5   dnnDvnm       2968 non-null    object
6   cretEvalCd    2968 non-null    object
7   capprTypeCd   2968 non-null    object
8   facDvcd       2968 non-null    object
9   orgClsCd      2968 non-null    object
10  dfecPaytYn    2968 non-null    object
11  weekCplanYn   2968 non-null    object
12  deptNm        2883 non-null    object
13  cretInptCd    2968 non-null    object
14  clsfNm        2883 non-null    object
15  facDvnm       2968 non-null    object
16  videoLtrYn    2968 non-null    object
17  subjtCd       2968 non-null    object
```

정보보호 2학년 과목

timtSmryCn	reprPrfsEnoNm	dnnDvnm	cretEvalCd	capprTypeCd	facDvcd	orgClsCd	dfecPaytYn	weekCplanYn	deptNm	cretInptCd	clsfNm	facDvnm	videoLtrYn	subjtCd
IT307(수 1,2,3)	전상훈	주간	2	A	26	20	Y	Y	정보보호	10	조교수	전핵	N	01760
IT306(금 6,7,8)	전상훈	주간	2	A	26	20	Y	Y	정보보호	10	조교수	전핵	N	01760
IT306(화 6,7,8)	김대엽	주간	2	A	22	20	Y	Y	정보보호	10	부교수	전선	N	07892
IT306(화 4,5),IT407(화 2,3)	양수미	주간	2	A	22	20	Y	Y	정보보호	10	부교수	전선	N	10058
IT215(금 3,4),IT407(금 1,2)	양수미	주간	2	A	22	20	Y	Y	정보보호	10	부교수	전선	N	10058
IT514(목 2,3,4)	고승철	주간	2	A	26	20	Y	Y	정보보호	10	특임교수	전핵	N	10484
IT407(목 6,7,8)	고승철	주간	2	A	26	20	Y	Y	정보보호	10	특임교수	전핵	N	10484
IT306(화 1,2,3)	김영미	주간	2	A	22	20	Y	Y	정보보호	10	겸임교수	전선	N	10638
IT306(월 1,2,3,4)	김영미	주간	2	A	22	20	Y	Y	정보보호	10	겸임교수	전선	N	10639
IT306(월 5,6,7,8)	김영미	주간	2	A	22	20	Y	Y	정보보호	10	겸임교수	전선	N	10639

데이터과학부 4학년 과목

subjtNm	lssnLangNm	ltrPrfsNm	estbDpmjCd	grd2LmtttHcnt	cretEvalNm	reprPrfsEno	pfevReflyYn	diclNo
알고리즘	한국어	황용득	2000511	38	상대평가	1174108	N	001
ICT 학점 연계 프로젝트 인턴 십4	영어	NaN	2000511	0	상대평가	ICEE001	N	001
캡스톤디자인1	한국어	황용득	2000511	12	상대평가	1174108	N	031
캡스톤디자인1	한국어	안홍렬	2000511	16	상대평가	1200091	N	033
캡스톤디자인1	한국어	김진현	2000511	12	상대평가	1240102	N	036

최종결과물 🙌

Jupyter Notebook 이 아닌 IDE 를 사용한 이유

한 파일에서 코드를 계속 작성하는 것은 생산성을 떨어뜨립니다. 그렇기 때문에 재사용 여부 등을 고려하여 작업단위로 **모듈화**하는 것은 매우 중요합니다. 이런 식으로 패키지(폴더구조)를 잡아가려는 습관이 필요합니다.

```
FLAG-Web-Scraping-Study/
├── .git/
├── .gitignore
├── .pytest_cache/
├── LICENSE
├── output/
├──   └── subjects_list.json # (예상 위치)
├── requirements.txt
├── scraping/
├──   ├── api_interaction.py
├──   ├── selenium_login.py
├──   └── selenium_utils.py
├── tests/
├──   ├── __init__.py
├──   ├── scraping/
├──   │   ├── __init__.py
├──   │   ├── test_api_interaction.py
├──   │   ├── test_selenium_login.py
├──   │   └── test_selenium_utils.py
├──   └── utils/
├──       ├── __init__.py
├──       └── test_file_utils.py
├── utils/
├──   ├── file_utils.py
├──   └── __init__.py # (추가 권장)
└── w4/
    ├── .env
    ├── data_info.ipynb
    ├── env.py # (이전 dotenv.py 와 유사한 파일로 추정)
    ├── initialize.py # (이전 initialize_driver 와 유사한 파일로 추정)
    ├── login.py # (이전 selenium_login 과 유사한 파일로 추정)
    └── main.py
```

수고하셨습니다! 🎉

리디북스, 네이버 웹툰, 로그인에서 배운 스크래핑 기법을 모두 활용해서 학교 포털까지 스크래핑해 보았습니다.
여러분들이라면 이 방법들을 더 창의적으로 활용해서 다양한 목적을 위해 사용할 수 있을 것 같습니다!
다양한 분야에 스크래핑을 활용해 보세요~

도전과제 🎯

- ✅ 저장한 JSON 데이터를 가지고 **시간표 경우의 수**를 자동으로 계산해 보여주는 프로그램을 만들어 보세요!
- ✅ 포털에서 다른 정보에도 접근해 보세요! 그러면서 새로운 스크래핑 방법들을 알아가 보세요!!
- ✅ 다양한 분야에 스크래핑 활용하기

BeautifulSoup

 Selenium

